

Hoja de Ruta Gratuita

RAG, Agentic AI, Agent Skills, MCP, LLMs Locales y Superagentes

*Alternativa gratuita a la especialización paga de IBM **RAG and Agentic AI Professional Certificate** en Coursera. Estos recursos cubren el mismo conocimiento y más, provenientes directamente de los creadores de cada herramienta.*

Camilo Hernandez Ruiz — Ingeniero de Software y Automatizaciones

 camihruiz24@gmail.com

1. Agent Skills (Estándar Abierto)

Agent Skills es un estandar abierto: carpetas con SKILL.md que cualquier LLM o agente puede usar. Adoptado por Claude, OpenAI Codex, Cursor, OpenClaw, Spring AI, Letta, Roo Code, y mas. Escribe una vez, usa en cualquier plataforma.

■ Introducing Agent Skills — Video oficial (YouTube) [GRATUITO] [OFICIAL]

Presentación oficial del estandar Agent Skills: que son, como funcionan, y por que son la forma mas eficiente de extender capacidades de cualquier agente o LLM.

→ <https://www.youtube.com/watch?v=hXgunHDwMR8>

→ <https://youtu.be/eWY6bHtid1o>

■ Anthropic Academy — Introduction to Agent Skills [GRATUITO] [OFICIAL]

Curso oficial: crear Skills, distribuir con plugins, conexión con subagentes, troubleshooting.

→ <https://anthropic.skilljar.com/introduction-to-agent-skills>

■ Repositorios de Skills [GRATUITO] [OPEN SOURCE]

github.com/anthropics/skills: 17+ skills open-source oficiales (docx, pdf, pptx, xlsx, frontend-design, MCP builder).
skills.sh: directorio de la comunidad con skills de terceros listos para instalar. agentskill.sh: directorio de 44k+ skills con escaneo de seguridad en dos capas e instalador /learn. Skillstore: marketplace curado de Agent Skills.
SkillsDirectory: directorio de las skills mas populares.

→ <https://github.com/anthropics/skills>

→ <https://skills.sh/>

→ <https://agentskill.sh>

→ <https://skillstore.io>

→ <https://www.skillsdirectory.org>

■ Especificación oficial — agentskills.io [GRATUITO] [ESTANDAR ABIERTO]

La especificación completa del estandar. Formato SKILL.md con YAML frontmatter, progressive disclosure (metadata -> body -> archivos extra), y guías de integración.

→ <https://agentskills.io/specification>

■ awesome-agent-skills — Índice del ecosistema completo [GRATUITO] [OPEN SOURCE]

Catalogos de skills de Anthropic, OpenAI, Microsoft, Google, Vercel, Supabase, HuggingFace, OpenClaw. Herramientas de authoring, validacion, y papers academicos.

→ <https://github.com/skillmatic-ai/awesome-agent-skills>

2. RAG (Retrieval-Augmented Generation)

Tecnica que permite a los LLMs consultar fuentes externas (documentos, bases de datos, APIs) antes de responder, produciendo respuestas mas precisas y actualizadas en lugar de depender solo de su entrenamiento.

Courses

■ DeepLearning.AI — Retrieval Augmented Generation (RAG) [GRATUITO]

Curso gratis de Andrew Ng para dominar chunking, embeddings, vector search y agentic RAG.

→ <https://www.deeplearning.ai/courses/retrieval-augmented-generation-rag/>

■ DeepLearning.AI — Building Applications with Vector Databases [GRATUITO]

Curso corto y practico para embeddings, similarity search y patrones de retrieval.

→ <https://www.deeplearning.ai/short-courses/building-applications-vector-databases/>

■ DeepLearning.AI — Knowledge Graphs for RAG [GRATUITO]

Curso para sumar grafos de conocimiento y retrieval estructurado a un RAG.

→ <https://www.deeplearning.ai/short-courses/knowledge-graphs-rag/>

Docs/Tutorials

■ Google Cloud — Vertex AI RAG Engine [GRATUITO] [OFICIAL]

Docs y quickstart oficiales para RAG administrado en Vertex AI, con ingestion y grounding sobre datos propios.

→ <https://cloud.google.com/vertex-ai/generative-ai/docs/rag-engine/rag-overview>

→ <https://cloud.google.com/vertex-ai/generative-ai/docs/rag-engine/rag-quickstart>

■ Google Cloud — Grounding with Vertex AI Search [GRATUITO] [OFICIAL]

Guia oficial para conectar Gemini a data stores y buscadores propios con grounding enterprise.

→ <https://cloud.google.com/vertex-ai/generative-ai/docs/grounding/grounding-with-vertex-ai-search>

■ NVIDIA — Deep Agents for Enterprise Search with AI-Q and LangChain [GRATUITO] [OFICIAL]

Tutorial oficial para agentes de busqueda enterprise con RAG, subagentes y tracing.

→ <https://developer.nvidia.com/blog/how-to-build-deep-agents-for-enterprise-search-with-nvidia-ai-q-and-langchain/>

■ NVIDIA — Document Processing Pipeline for RAG with Nemotron [GRATUITO] [OFICIAL]

Guia oficial para extraer PDFs, generar embeddings, reranear y citar fuentes.

→ <https://developer.nvidia.com/blog/how-to-build-a-document-processing-pipeline-for-rag-with-nemotron/>

■ Google Developers Codelabs — Building AI Agents with Vertex AI Agent Builder [GRATUITO] [OFICIAL]

Codelab oficial y gratuito para construir agentes y apps LLM con Vertex AI Agent Builder; muy buen fit para patrones agenticos y retrieval.

→ <https://codelabs.developers.google.com/devsite/codelabs/building-ai-agents-vertexai>

■ OpenAI — File search y function calling [GRATUITO] [OFICIAL]

Docs oficiales para retrieval sobre archivos y tool use en asistentes y flujos agenticos.

→ <https://platform.openai.com/docs/guides/file-search>

→ <https://platform.openai.com/docs/guides/function-calling>

3. LangChain + LangGraph

LangChain es el framework mas popular para construir aplicaciones con LLMs: cadenas de prompts, herramientas, y agentes. LangGraph lo extiende con grafos de estado que permiten memoria, iteracion, logica condicional, y workflows multi-agente complejos.

■ LangChain Academy — Introduction to LangGraph [GRATUITO] [OFICIAL]

Curso oficial gratuito. 6 modulos: state, nodes, edges, memory, human-in-the-loop, deployment.

→ <https://academy.langchain.com/courses/intro-to-langgraph>

■ DeepLearning.AI — AI Agents in LangGraph [GRATUITO]

Por Harrison Chase. Agente desde cero, LangGraph, agentic search, persistencia.

→ <https://deeplearning.ai/short-courses/ai-agents-in-langgraph/>

■ DeepLearning.AI — Long-Term Agentic Memory [GRATUITO]

Memoria semantica, episodica, procedural. Proyecto: email agent con routing.

→ <https://deeplearning.ai/short-courses/long-term-agentic-memory-with-langgraph/>

■ Docs oficiales LangChain/LangGraph [GRATUITO] [OFICIAL]

Tutoriales, RAG agents, SQL agents, multi-agent patterns.Codigo fuente completo.

→ <https://docs.langchain.com/oss/python/learn>

→ <https://github.com/langchain-ai/langgraph>

4. MCP (Model Context Protocol)

Protocolo abierto creado por Anthropic que estandariza como los LLMs se conectan a herramientas externas, bases de datos, y APIs. Funciona como un USB-C universal: un solo protocolo para que cualquier modelo acceda a cualquier servicio, reemplazando integraciones custom por conexion via servidores MCP reutilizables.

■ Hugging Face — MCP Course (con Anthropic) [GRATUITO] [CERTIFICADO]

Curso gratuito con Anthropic. Asignaciones practicas, challenges, certificado.

→ <https://huggingface.co/learn/mcp-course/>

■ Anthropic — Introduction to Model Context Protocol [GRATUITO] [OFICIAL]

Arquitectura MCP, primitivas (tools, resources, prompts), Python SDK, MCP Inspector.

→ <https://anthropic.skilljar.com/introduction-to-model-context-protocol>

■ Microsoft — MCP for Beginners (GitHub) [GRATUITO] [OPEN SOURCE]

Open-source: Python, TypeScript, .NET, Java, Rust. Spec MCP 2025-11-25.

→ <https://github.com/microsoft/mcp-for-beginners>

5. LLMs Locales — Fine-Tuning y Deploy On-Premise

Descargar modelos open-weight (Llama, Qwen, DeepSeek, Mistral, gpt-oss de OpenAI), hacer fine-tuning con LoRA/QLoRA para tareas específicas de empresa, convertir a GGUF, y servir localmente con Ollama, LM Studio, o vLLM. Privacidad total, sin costos por token, y modelos especializados en tu dominio.

■ Unsloth — Docs + Notebooks en Google Colab [GRATUITO] [OPEN SOURCE]

Fine-tuning completo: QLoRA vs LoRA, datasets, GGUF para Ollama. Modelo 8B en GPU 12GB.

→ <https://unsloth.ai/docs>

→ <https://github.com/unslothai/unsloth>

■ Hugging Face — Unsloth + TRL [GRATUITO] [OFICIAL]

Tutorial oficial HF. Compatible con Hub, transformers, PEFT.

→ <https://huggingface.co/blog/unsloth-trl>

■ HF + Unsloth — Fine-tuning gratis en HF Jobs [GRATUITO] [CREDITOS GRATIS]

Creditos gratuitos para fine-tunear en infra cloud de HF.

→ <https://huggingface.co/blog/unsloth-jobs>

■ Decodingml — Fine-tune and Deploy Open-Source LLMs [GRATUITO] [OPEN SOURCE]

Pipeline completo: APIs de prototipo a modelos open-source on-prem.

→ <https://www.decodingai.com/>

■ Ollama — Docs oficiales [GRATUITO] [OPEN SOURCE]

Llama, DeepSeek, Qwen local. Compatible LangChain/RAG. macOS/Linux/Windows/Docker.

→ <https://ollama.com>

→ <https://github.com/ollama/ollama>

■ SitePoint — Fine-Tune Local LLMs 2026 [GRATUITO]

Guia end-to-end: fine-tuning vs RAG vs prompting, Unsloth, GGUF, Ollama + FastAPI.

→ <https://www.sitepoint.com/fine-tune-local-llms-2026/>

6. Sistemas Multi-Agente (CrewAI, AG2/AutoGen)

Frameworks para crear equipos de agentes de IA que colaboran entre si: cada agente tiene un rol especializado (investigador, escritor, critico) y se comunican para resolver tareas complejas que un solo agente no podria manejar.

■ DeepLearning.AI — CrewAI y multi-agent systems [GRATUITO]

Orquestacion, collaboration patterns, workflows especializados.

→ <https://deeplearning.ai/short-courses/>

■ Docs oficiales CrewAI y AutoGen [GRATUITO] [OFICIAL]

CrewAI: workflows estructurados. AutoGen: conversaciones multi-agente.

→ <https://docs.crewai.com>

→ <https://microsoft.github.io/autogen>

7. IA Multimodal

Modelos que procesan y generan multiples tipos de datos: texto, imagenes, audio, y video. Permite construir aplicaciones que entienden fotos, transcriben voz, generan imagenes, y combinan todo en un solo flujo de trabajo.

■ DeepLearning.AI — Short courses multimodales [GRATUITO]

Whisper (audio), CLIP (imagen-texto), vision, generacion de imagenes.

→ <https://deeplearning.ai/short-courses/>

8. Deploy a Produccion (Multi-Cloud)

Llevar tu aplicacion de IA desde tu maquina local a servidores accesibles al mundo. Desde plataformas simples (push-to-deploy en un click) hasta AWS enterprise con Lambda serverless. Cada opcion tiene trade-offs de costo, complejidad, y escalabilidad.

■ Advent of Agents — Google Cloud (25 dias) [GRATUITO] [GOOGLE CLOUD]

Agente basico a multi-agente en produccion. Gemini, ADK, Vertex AI, MCP.

→ <https://adventofagents.com>

■ AWS — FastAPI + Lambda + Docker [GRATUITO]

Deploy serverless con FastAPI, Mangum, Lambda, API Gateway, ECR, SAM.

→ <https://aws.amazon.com/blogs/machine-learning/>

→ https://dev.to/dev_insights/deploy-fastapi-on-aws-lambda-with-docker-2025-3a3a

■ Railway — Push-to-deploy desde GitHub [TIER GRATIS]

Conecta GitHub, click deploy, URL publica. \$5 creditos. Ideal MVPs.

→ <https://railway.app>

■ Render — Deploy con free tier y workers [TIER GRATIS]

Free tier, Postgres/Redis managed, background workers incluidos.

→ <https://render.com>

■ Fly.io — Deploy global en edge [TIER GRATIS]

35+ regiones, GPUs, scale-to-zero, static IPs. Baja latencia global.

→ <https://fly.io>

■ DigitalOcean App Platform [TIER GRATIS]

Source builds, Postgres/Redis, CDN. Balance precio/simplicidad.

→ <https://www.digitalocean.com/products/app-platform>

9. Superagentes Personales (OpenClaw / MaxClaw)

La nueva generacion de asistentes de IA que se conectan con tus cuentas reales (WhatsApp, Telegram, Slack, email, calendario, GitHub) y ejecutan tareas autonomamente. Corren en tu servidor local o en la nube, y los controlas desde un chat en el celular como si hablaras con un asistente humano.

Tabla Resumen: Especializacion Paga de IBM vs. Ruta Gratuita

Tema	IBM (Paga)	Ruta Gratuita
Agent Skills (estandar abierto agentskills.io)	NO cubre	agentskills.io + Anthropic Academy + awesome-agent-skills + skillkit
RAG pipelines, FAISS, vectores	Cubre	DeepLearning.AI — RAG course
LangChain + LangGraph	Cubre	LangChain Academy + DeepLearning.AI (3 cursos)
MCP (Model Context Protocol)	Cubre (FastMCP)	HuggingFace + Anthropic + Microsoft
LLMs locales: fine-tuning, Ollama, open-weight	NO cubre	Unsloth + HF TRL + Ollama + Decodingml
Multi-agente (CrewAI, AG2)	Cubre	DeepLearning.AI + docs oficiales
Multimodal AI	Cubre	DeepLearning.AI short courses
Deploy multi-cloud (AWS, Railway, Fly.io, etc.)	Parcial (Gradio, Flask)	Advent of Agents + AWS + Railway/Render/Fly.io/DO
Superagentes personales (OpenClaw, MaxClaw)	NO cubre	OpenClaw + MaxClaw + NemoClaw + guias

Ventaja de la ruta gratuita: La especializacion paga de IBM no cubre Agent Skills (estandar abierto), fine-tuning/deployment local de modelos open-weight, ni superagentes personales (OpenClaw/MaxClaw). Estos tres temas son criticos para privacidad de datos, reduccion de costos, modelos especializados, y asistentes autonomos que funcionan con cualquier LLM.