

Hoja de Ruta Gratuita

Transformers, RAG, Agentic AI, Agent Skills, MCP, LLMs Locales y Superagentes

*Alternativa gratuita a la especialización paga de IBM **RAG and Agentic AI Professional Certificate** en Coursera. Estos recursos cubren el mismo conocimiento y más, provenientes directamente de los creadores de cada herramienta.*

Camilo Hernandez Ruiz — Ingeniero de Software y Automatizaciones

 camihruiz24@gmail.com

1. Agent Skills (Estándar Abierto)

Agent Skills es un estandar abierto: carpetas con SKILL.md que cualquier LLM o agente puede usar. Adoptado por Claude, OpenAI Codex, Cursor, OpenClaw, Spring AI, Letta, Roo Code, y mas. Escribe una vez, usa en cualquier plataforma.

Courses

■ Introducing Agent Skills — Video oficial (YouTube) [GRATUITO] [OFICIAL]

Presentacion oficial del estandar y su flujo de trabajo basico.

→ <https://www.youtube.com/watch?v=hXgunHDwMR8>

2. Fundamentos de Transformers y LLMs

Antes de meterse en RAG, agentes, MCP o fine-tuning local, conviene entender que es un Transformer, como se diferencian las arquitecturas encoder, decoder y encoder-decoder, como usar modelos desde el Hub de Hugging Face, y que papel juegan tokenization, datasets y ajuste fino.

Courses

■ Hugging Face — LLM Course [GRATUITO] [OFICIAL]

Curso oficial, gratuito y muy solido para entender Transformers, usar pipeline(), trabajar con el Hub, hacer fine-tuning y dominar Datasets/Tokenizers antes de pasar a RAG y agentes.

→ <https://huggingface.co/learn/llm-course/es/chapter1/1>

→ <https://huggingface.co/learn/llm-course/es>

3. RAG (Retrieval-Augmented Generation)

Tecnica que permite a los LLMs consultar fuentes externas (documentos, bases de datos, APIs) antes de responder, produciendo respuestas mas precisas y actualizadas en lugar de depender solo de su entrenamiento.

Courses

■ DeepLearning.AI — Retrieval Augmented Generation (RAG) [GRATUITO]

Curso gratis de Andrew Ng para dominar chunking, embeddings, vector search y agentic RAG.

→ <https://www.deeplearning.ai/courses/retrieval-augmented-generation-rag/>

■ DeepLearning.AI — Building Applications with Vector Databases [GRATUITO]

Curso corto y practico para embeddings, similarity search y patrones de retrieval.

→ <https://www.deeplearning.ai/short-courses/building-applications-vector-databases/>

■ DeepLearning.AI — Knowledge Graphs for RAG [GRATUITO]

Curso para sumar grafos de conocimiento y retrieval estructurado a un RAG.

→ <https://www.deeplearning.ai/short-courses/knowledge-graphs-rag/>

Docs/Tutorials

■ Google Cloud — Vertex AI RAG Engine [GRATUITO] [OFICIAL]

Docs y quickstart oficiales para RAG administrado en Vertex AI, con ingestion y grounding sobre datos propios.

→ <https://cloud.google.com/vertex-ai/generative-ai/docs/rag-engine/rag-overview>

→ <https://cloud.google.com/vertex-ai/generative-ai/docs/rag-engine/rag-quickstart>

■ Google Cloud — Grounding with Vertex AI Search [GRATUITO] [OFICIAL]

Guia oficial para conectar Gemini a data stores y buscadores propios con grounding enterprise.

→ <https://cloud.google.com/vertex-ai/generative-ai/docs/grounding/grounding-with-vertex-ai-search>

■ NVIDIA — Deep Agents for Enterprise Search with AI-Q and LangChain [GRATUITO] [OFICIAL]

Tutorial oficial para agentes de busqueda enterprise con RAG, subagentes y tracing.

→ <https://developer.nvidia.com/blog/how-to-build-deep-agents-for-enterprise-search-with-nvidia-ai-q-and-langchain/>

■ NVIDIA — Document Processing Pipeline for RAG with Nemotron [GRATUITO] [OFICIAL]

Guia oficial para extraer PDFs, generar embeddings, reranear y citar fuentes.

→ <https://developer.nvidia.com/blog/how-to-build-a-document-processing-pipeline-for-rag-with-nemotron/>

■ Google Developers Codelabs — Building AI Agents with Vertex AI Agent Builder [GRATUITO] [OFICIAL]

Codelab oficial y gratuito para construir agentes y apps LLM con Vertex AI Agent Builder; muy buen fit para patrones agenticos y retrieval.

→ <https://codelabs.developers.google.com/devsite/codelabs/building-ai-agents-vertexai>

■ OpenAI — File search y function calling [GRATUITO] [OFICIAL]

Docs oficiales para retrieval sobre archivos y tool use en asistentes y flujos agenticos.

→ <https://platform.openai.com/docs/guides/file-search>

→ <https://platform.openai.com/docs/guides/function-calling>

4. MCP (Model Context Protocol)

Protocolo abierto creado por Anthropic que estandariza como los LLMs se conectan a herramientas externas, bases de datos, y APIs. Funciona como un USB-C universal: un solo protocolo para que cualquier modelo acceda a cualquier servicio, reemplazando integraciones custom por conexion via servidores MCP reutilizables.

■ Hugging Face — MCP Course (con Anthropic) [GRATUITO] [CERTIFICADO]

Curso gratuito con Anthropic. Asignaciones practicas, challenges, certificado.

→ <https://huggingface.co/learn/mcp-course/>

■ Anthropic — Introduction to Model Context Protocol [GRATUITO] [OFICIAL]

Arquitectura MCP, primitivas (tools, resources, prompts), Python SDK, MCP Inspector.

→ <https://anthropic.skilljar.com/introduction-to-model-context-protocol>

■ Microsoft — MCP for Beginners (GitHub) [GRATUITO] [OPEN SOURCE]

Open-source: Python, TypeScript, .NET, Java, Rust. Spec MCP 2025-11-25.

→ <https://github.com/microsoft/mcp-for-beginners>

5. LangChain + LangGraph

LangChain es el framework mas popular para construir aplicaciones con LLMs: cadenas de prompts, herramientas, y agentes. LangGraph lo extiende con grafos de estado que permiten memoria, iteracion, logica condicional, y workflows multi-agente complejos.

■ LangChain Academy — Introduction to LangGraph [GRATUITO] [OFICIAL]

Curso oficial gratuito. 6 modulos: state, nodes, edges, memory, human-in-the-loop, deployment.

→ <https://academy.langchain.com/courses/intro-to-langgraph>

■ DeepLearning.AI — AI Agents in LangGraph [GRATUITO]

Por Harrison Chase. Agente desde cero, LangGraph, agentic search, persistencia.

→ <https://deeplearning.ai/short-courses/ai-agents-in-langgraph/>

■ DeepLearning.AI — Long-Term Agentic Memory [GRATUITO]

Memoria semantica, episodica, procedural. Proyecto: email agent con routing.

→ <https://deeplearning.ai/short-courses/long-term-agentic-memory-with-langgraph/>

■ Docs oficiales LangChain/LangGraph [GRATUITO] [OFICIAL]

Tutoriales, RAG agents, SQL agents, multi-agent patterns.Codigo fuente completo.

→ <https://docs.langchain.com/oss/python/learn>

→ <https://github.com/langchain-ai/langgraph>

6. Sistemas Multi-Agente (CrewAI, AG2/AutoGen)

Frameworks para crear equipos de agentes de IA que colaboran entre si: cada agente tiene un rol especializado (investigador, escritor, critico) y se comunican para resolver tareas complejas que un solo agente no podria manejar.

■ DeepLearning.AI — Design, Develop, and Deploy Multi-Agent Systems with CrewAI [GRATUITO]

Aprende a construir sistemas multi-agente que automaticen flujos de trabajo complejos end-to-end.

→

<https://learn.deeplearning.ai/courses/design-develop-and-deploy-multi-agent-systems-with-crewai/lesson/rc39v/welcome>

→ <https://docs.crewai.com>

■ Framework AutoGen para sistemas multi-agente [GRATUITO] [OFICIAL]

AutoGen: conversaciones multi-agente.

→ <https://www.deeplearning.ai/short-courses/ai-agentic-design-patterns-with-autogen/>

→ <https://microsoft.github.io/autogen>

■ AG2 — Fork open source de AutoGen (formerly AutoGen) [GRATUITO] [OPEN SOURCE]

AG2 es la evolucion independiente de AutoGen 0.2, mantenida por la comunidad bajo la org ag2ai. Misma API (import autogen), licencia Apache 2.0, con roadmap propio separado de Microsoft.

→ <https://ag2.ai>

→ <https://github.com/ag2ai/ag2>

→ <https://docs.ag2.ai>

■ Google ADK — Agent Development Kit [GRATUITO] [OFICIAL]

Framework oficial de Google para construir sistemas multi-agente. Disponible en Python, TypeScript, Go y Java. Soporta LLM agents, Workflow agents (sequential, loop, parallel nativo) y Custom agents. Incluye el protocolo A2A (Agent-to-Agent) para comunicacion entre agentes de distintos frameworks. Integracion nativa con Google Cloud (Vertex AI, Cloud Run, GKE).

→ <https://google.github.io/adk-docs/>

→ <https://github.com/google/adk-python>

■ Amazon Bedrock Agents — Multi-agent en AWS [PAGO] [AWS]

Servicio administrado de AWS para construir sistemas multi-agente sin gestionar infraestructura. Modelo supervisor + colaboradores: cada agente tiene rol especializado, acceso a APIs (action groups), knowledge bases (RAG), guardrails y memory retention. Ideal para stacks AWS enterprise. Alto vendor lock-in vs frameworks open source. AgentCore permite ademas desplegar agentes de cualquier framework (AG2, ADK) en infraestructura AWS.

→ <https://aws.amazon.com/bedrock/agents/>

→ <https://docs.aws.amazon.com/bedrock/latest/userguide/agents.html>

■ DeepLearning.AI — Serverless Agentic Workflows with Amazon Bedrock [GRATUITO]

Curso practico para construir flujos agenticos serverless directamente sobre Bedrock: invocacion de agentes, action groups, tool use y despliegue sin gestionar infraestructura.

→ <https://learn.deeplearning.ai/courses/serverless-agentic-workflows-with-amazon-bedrock/>

7. LLMs Locales — Fine-Tuning y Deploy On-Premise

Descargar modelos open-weight (Gemma, Llama, Qwen, DeepSeek, Mistral, gpt-oss de OpenAI), hacer fine-tuning con LoRA/QLoRA para tareas especificas de empresa, convertir a GGUF, y servir localmente con Ollama, LM Studio, o vLLM. Privacidad total, sin costos por token, y modelos especializados en tu dominio.

■ Google — Gemma 4 (introduccion) [GRATUITO] [OPEN SOURCE]

Familia open-weight de Google con licencia Apache 2.0. Multimodal, multilingual, contexto 128K. Corre en Ollama y HF.

→ <https://youtu.be/W2xVSO6eUWY>

→ <https://youtu.be/0mSdAr7RFZU>

■ Unsloth — Docs + Notebooks en Google Colab [GRATUITO] [OPEN SOURCE]

Fine-tuning completo: QLoRA vs LoRA, datasets, GGUF para Ollama. Modelo 8B en GPU 12GB.

→ <https://unsloth.ai/docs>

→ <https://github.com/unslothai/unsloth>

■ Hugging Face — Unsloth + TRL [GRATUITO] [OFICIAL]

Tutorial oficial HF. Compatible con Hub, transformers, PEFT.

→ <https://huggingface.co/blog/unsloth-trl>

■ HF + Unsloth — Fine-tuning gratis en HF Jobs [GRATUITO] [CREDITOS GRATIS]

Creditos gratuitos para fine-tunear en infra cloud de HF.

→ <https://huggingface.co/blog/unsloth-jobs>

■ Decodingml — Fine-tune and Deploy Open-Source LLMs [GRATUITO] [OPEN SOURCE]

Pipeline completo: APIs de prototipo a modelos open-source on-prem.

→ <https://www.decodingai.com/>

■ Ollama — Docs oficiales [GRATUITO] [OPEN SOURCE]

Llama, DeepSeek, Qwen local. Compatible LangChain/RAG. macOS/Linux/Windows/Docker.

→ <https://ollama.com>

→ <https://github.com/ollama/ollama>

■ SitePoint — Fine-Tune Local LLMs 2026 [GRATUITO]

Guia end-to-end: fine-tuning vs RAG vs prompting, Unsloth, GGUF, Ollama + FastAPI.

→ <https://www.sitepoint.com/fine-tune-local-llms-2026/>

8. IA Multimodal

Modelos que procesan y generan multiples tipos de datos: texto, imagenes, audio, y video. Permite construir aplicaciones que entienden fotos, transcriben voz, generan imagenes, y combinan todo en un solo flujo de trabajo.

■ DeepLearning.AI — Short courses (multimodal) [GRATUITO]

Catalogo corto con cursos sobre audio, vision y generacion multimodal.

→ <https://deeplearning.ai/short-courses/>

9. Deploy a Produccion (Multi-Cloud)

Llevar tu aplicacion de IA desde tu maquina local a servidores accesibles al mundo. Desde plataformas simples (push-to-deploy en un click) hasta AWS enterprise con Lambda serverless. Cada opcion tiene trade-offs de costo, complejidad, y escalabilidad.

AWS / Bedrock — Fundamentos y Ecosistema

■ AWS — Learn About AI (portal oficial) [GRATUITO] [OFICIAL]

Portal de aprendizaje oficial de AWS para IA y ML: rutas de aprendizaje, certificaciones, tutoriales de Bedrock, SageMaker y servicios de IA gestionados.

→ <https://aws.amazon.com/es/training/learn-about/ai/>

■ AWS Skill Builder — Introduction to Generative AI: Art of the Possible [GRATUITO] [OFICIAL]

Modulo oficial introductorio de AWS Skill Builder: conceptos clave de GenAI, casos de uso empresariales y posibilidades con los servicios de AWS.

→ <https://skillbuilder.aws/learn/ZEVZZ1D4AS/introduction-to-generative-ai--art-of-the-possible/>

■ Advent of Agents — Google Cloud (25 dias) [GRATUITO] [GOOGLE CLOUD]

Agente basico a multi-agente en produccion. Gemini, ADK, Vertex AI, MCP.

→ <https://adventofagents.com>

■ AWS Lambda — Container images [GRATUITO]

Docs oficiales para desplegar funciones Lambda como imagenes Docker.

→ <https://docs.aws.amazon.com/lambda/latest/dg/images-create.html>

→ <https://docs.aws.amazon.com/lambda/latest/dg/python-image.html>

■ DEV Community — FastAPI on AWS Lambda with Docker [GRATUITO]

Guia practica con FastAPI, Mangum, ECR y Lambda para un deploy end-to-end.

→ https://dev.to/dev_insights/deploy-fastapi-on-aws-lambda-with-docker-2025-3a3a

■ Railway — Push-to-deploy desde GitHub [TIER GRATIS]

Conecta GitHub, click deploy, URL publica. \$5 creditos. Ideal MVPs.

→ <https://railway.app>

■ Render — Deploy con free tier y workers [TIER GRATIS]

Free tier, Postgres/Redis managed, background workers incluidos.

→ <https://render.com>

■ Fly.io — Deploy global en edge [TIER GRATIS]

35+ regiones, GPUs, scale-to-zero, static IPs. Baja latencia global.

→ <https://fly.io>

■ DigitalOcean App Platform [TIER GRATIS]

Source builds, Postgres/Redis, CDN. Balance precio/simplicidad.

→ <https://www.digitalocean.com/products/app-platform>

10. Super 24/7 Agents

Agentes de IA que corren continuamente, sin supervision humana constante, y toman el control de sistemas reales: navegan la web, abren apps, ejecutan comandos, gestionan archivos, envian emails y responden mensajes. Operan 24/7 en tu servidor local o en la nube, y los controlas desde un simple chat como si hablaras con un asistente humano.

OpenClaw, proyecto independiente creado por Peter Steinberger y presentado a inicios de 2026, ayudo a empujar esta tendencia de agentes que operan computadoras reales. Su propuesta llamo la atencion por el control total del computador y las cuentas del usuario, convirtiéndose en un asistente personal siempre activo.

n8n — Automatizacion low-code personal y empresarial

■ n8n — Workflow Automation (open source) [GRATUITO] [OPEN SOURCE]

Herramienta low-code de automatizacion de flujos que conecta mas de 500 apps (Slack, GitHub, Gmail, Postgres, HubSpot, Stripe, Google Workspace) mediante nodos visuales en un canvas. Permite escribir codigo JavaScript o Python directamente cuando se necesita logica avanzada, sin depender exclusivamente del enfoque low-code.

Soporta MCP para integraciones con agentes de IA. Funciona para uso personal (self-hosted gratis con Docker) y para empresas (RBAC, SSO/SAML, audit logs, control de versiones con git). Sin vendor lock-in: tu infra, tus datos.

→ <https://n8n.io>

→ <https://github.com/n8n-io/n8n>

Agentes tipo OpenClaw

■ OpenClaw — Proyecto independiente [COMUNIDAD]

Proyecto de computer use creado por Peter Steinberger. Se enfoca en automatizar tareas sobre una computadora real o virtual, llevando la idea de un asistente personal que puede operar interfaces, coordinar acciones y mantener flujos de trabajo continuos.

→ <https://openclaw.ai/>

■ MaxClaw — Agente local en Go [OPEN SOURCE]

Agente open-source autoalojado escrito en Go. Ofrece CLI, interfaz web y desktop con sesiones, memoria persistente, tareas programadas e integraciones multi-canal (Telegram, WhatsApp, Discord). Implementa un ciclo de vida adaptativo de seis capas con recuperacion de errores, compresion de contexto y fallback de modelos. Compatible con Anthropic y OpenAI.

→ <https://github.com/Lichas/maxclaw>

■ KimiClaw [OPEN SOURCE]

Variante de agente de uso de computadora construida sobre los modelos Kimi de Moonshot AI, enfocada en tareas de automatizacion web y procesamiento de documentos de larga duracion.

→ <https://www.kimi.com/bot>

■ KiloClaw — Extension de KiloCode [OPEN SOURCE]

Extensión de KiloCode para ser alternativa a OpenClaw

→ <https://kilo.ai/kiloclaw>

■ NemoClaw — Agente basado en NVIDIA NeMo [OPEN SOURCE]

Agente de uso de computadora construido sobre el ecosistema NeMo de NVIDIA, orientado a automatizacion de flujos de trabajo en entornos con aceleracion GPU y modelos LLM on-premise.

→ <https://www.nvidia.com/es-la/ai/nemoclaw/>

■ Perplexity Computer — Agente de Perplexity AI [OFICIAL]

Agente de uso de computadora de Perplexity AI que combina busqueda en tiempo real con control de escritorio, permitiendo investigar, resumir y ejecutar tareas basadas en informacion actualizada de la web.

→ <https://www.perplexity.ai/computer/new>

Tabla Resumen: Especializacion Paga de IBM vs. Ruta Gratuita

Tema	IBM (Paga)	Ruta Gratuita
Fundamentos de Transformers y LLMs	Parcial	Hugging Face — LLM Course
Agent Skills (estandar abierto agentskills.io)	NO cubre	agentskills.io + Anthropic Academy + skills.sh + agentskill.sh
RAG pipelines, FAISS, vectores	Cubre	DeepLearning.AI — RAG course

Tema	IBM (Paga)	Ruta Gratuita
LangChain + LangGraph	Cubre	LangChain Academy + DeepLearning.AI (3 cursos)
MCP (Model Context Protocol)	Cubre (FastMCP)	HuggingFace + Anthropic + Microsoft
LLMs locales: fine-tuning, Ollama, open-weight	NO cubre	Unsloth + HF TRL + Ollama + Decoding AI Magazine
Multi-agente (CrewAI, AG2)	Cubre	DeepLearning.AI + docs oficiales
Multimodal AI	Cubre	DeepLearning.AI short courses
Deploy multi-cloud (AWS, Railway, Fly.io, etc.)	Parcial (Gradio, Flask)	Advent of Agents + AWS Lambda docs + Railway/Render/Fly.io/DO
Super 24/7 Agents	NO cubre	OpenClaw + MaxClaw + KimiClaw + KiloClaw + NemoClaw + Perplexity Computer + n8n

Ventaja de la ruta gratuita: La especialización paga de IBM no cubre Agent Skills (estandar abierto), fine-tuning/deployment local de modelos open-weight, ni superagentes personales (OpenClaw/MaxClaw). Estos tres temas son críticos para privacidad de datos, reducción de costos, modelos especializados, y asistentes autónomos que funcionan con cualquier LLM.